

Segmentation Clients d'un Centre Commercial

K-means + ANOVA

Don De Dieu Mboumba

Étudiant en Master Data Science

Année 2025/2026

Mots-clés :

K-means · ANOVA · Clustering · Python · sklearn · scipy

Table des matières

1	Introduction & Contexte	3
1.1	Présentation du projet	3
1.2	Description des données	3
1.3	Environnement technique	3
2	Exploration des données (EDA)	4
2.1	Statistiques descriptives	4
2.2	Distribution des variables	4
2.3	Analyse des corrélations	6
2.4	Analyse du genre	7
3	Préparation des données	7
3.1	Nettoyage et encodage	7
3.2	Normalisation des données	8
4	Détermination du nombre optimal de clusters	8
4.1	L'algorithme K-means	8
4.2	Méthode Elbow	9
4.3	Silhouette Score	9
4.4	Résultats	10
5	Application du K-means et Visualisation	10
5.1	Entraînement du modèle final	10
5.2	Visualisation 2D principale	11
5.3	Réduction de dimension — PCA	12
5.4	Radar Chart et Heatmap	13
6	Profils des Segments Clients	13
6.1	Tableau récapitulatif	13
6.2	Qui dépense le plus ? Interprétation et cibles marketing	14
6.3	Description détaillée des segments	15
6.3.1	Cluster 0 — Modérés équilibrés	15
6.3.2	Cluster 1 — Jeunes dépensiers	15
6.3.3	Cluster 2 — Clients VIP	15
6.3.4	Cluster 3 — Hauts revenus économes	16
6.3.5	Cluster 4 — Budget serré	16
7	Validation Statistique — ANOVA	16
7.1	Stratégie de validation	17
7.2	Étape 1 — Test de normalité (Shapiro-Wilk)	17
7.3	Étape 2 — Test d'homogénéité des variances (Levene)	18
7.4	Étape 3 — ANOVA à 1 facteur	18
7.4.1	Résultats numériques	19
7.5	Étape 4 — Tests post-hoc de Tukey HSD	19
8	Conclusion & Perspectives	20

8.1	Synthèse des résultats	20
8.2	Limites du projet	21
8.3	Perspectives d'amélioration	21
8.4	Compétences développées	21
	Récapitulatif des métriques clés	22

1. Introduction & Contexte

1.1. Présentation du projet

Ce rapport présente un projet complet de **segmentation clients** appliqué à un centre commercial. À partir d'un jeu de données de **200 clients** caractérisés par leur âge, leur revenu annuel et leur score de dépense, l'objectif est de regrouper automatiquement les clients en profils homogènes grâce à l'algorithme **K-means**, puis de valider statistiquement ces groupes à l'aide d'une **ANOVA** (Analysis of Variance).

Idée générale en termes simples

Imagine que tu travailles dans un centre commercial et que tu veux mieux comprendre ta clientèle. Plutôt que de traiter tous les clients de la même façon, tu cherches à les diviser en groupes naturels : les jeunes qui dépensent beaucoup, les seniors économes, les clients VIP... Une fois ces groupes identifiés, tu peux adapter ta stratégie marketing à chaque profil.

1.2. Description des données

Table 1. Description du jeu de données

Variable	Description
CustomerID	Identifiant unique du client (supprimé avant modélisation)
Genre	Sexe du client (Male / Female)
Age	Âge du client en années (18 – 70)
Annual Income (k\$)	Revenu annuel en milliers de dollars (15 – 137)
Spending Score (1-100)	Score de propension à dépenser, attribué par le centre (1 – 100)

1.3. Environnement technique

Listing 1. Imports principaux du projet

```
1 import pandas as pd
2 import numpy as np
3 import matplotlib.pyplot as plt
4 import seaborn as sns
5 from sklearn.preprocessing import StandardScaler
6 from sklearn.cluster import KMeans
7 from sklearn.decomposition import PCA
8 from sklearn.metrics import silhouette_score
9 from scipy.stats import f_oneway, shapiro, levene
```

```
10 from statsmodels.stats.multicomp import pairwise_tukeyhsd
```

2. Exploration des données (EDA)

2.1. Statistiques descriptives

Avant toute modélisation, l'analyse exploratoire permet de comprendre la structure des données. Le tableau ci-dessous résume les statistiques principales des trois variables numériques.

Table 2. Statistiques descriptives des variables numériques

Variable	Min	Max	Moyenne	Médiane	Écart-type	N
Age	18	70	38,85	36	13,97	200
Annual Income (k\$)	15	137	60,56	61,5	26,26	200
Spending Score (1-100)	1	99	50,20	50	25,82	200

2.2. Distribution des variables




Figure 1. Distribution des 3 variables numériques. *Ligne 1* : histogrammes avec ligne de moyenne (blanche, tirets) et médiane (couleur, pointillés). *Ligne 2* : boxplots correspondants.

Comment lire un histogramme et un boxplot ?

Histogramme : L'axe horizontal représente les valeurs possibles (ex. les âges de 18 à 70 ans), et l'axe vertical indique combien de clients se trouvent dans chaque intervalle. Une barre haute signifie « beaucoup de clients ont cette valeur ».

Boxplot : La barre centrale est la *médiane* (50% des clients en dessous, 50% au-dessus). Le rectangle coloré contient les 50% du milieu (du 1er au 3e quartile). Les moustaches s'étendent jusqu'aux valeurs extrêmes raisonnables ; les points isolés sont des valeurs atypiques.

Observations clés :

- **Âge :** distribution légèrement asymétrique à droite, avec un pic principal entre **30 et 38 ans** (médiane = 36 ans, moyenne = 38,85 ans). La clientèle est majoritairement jeune à d'âge moyen, avec une représentation plus faible des clients de plus de 55 ans.
- **Revenu annuel :** distribution bimodale avec deux concentrations distinctes : une première autour de **20–30 k\$** et une seconde plus marquée autour de **65–75 k\$**, révélant l'existence de deux classes économiques bien séparées dans la clientèle.
- **Spending Score :** distribution **quasi uniforme** sur toute la plage de valeurs (1 à 99), avec un léger pic autour de 45–55 correspondant à la médiane (50) et à la moyenne (50,20). Il n'existe pas de comportement de consommation dominant — les profils sont très variés.

2.3. Analyse des corrélations




Figure 2. Gauche : heatmap des corrélations de Pearson (rouge = corrélation positive, bleu = négative, blanc = indépendance). Droite : nuage de points Revenu vs Spending Score, coloré par l'âge du client.

Coefficient de corrélation de Pearson

Le coefficient r mesure la force et le sens de la relation linéaire entre deux variables continues. Il varie entre -1 et $+1$:

Définition mathématique

$$r_{XY} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \cdot \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

- $r = +1$: relation linéaire parfaite et positive
- $r = -1$: relation linéaire parfaite et négative
- $r \approx 0$: pas de relation linéaire
- $|r| > 0,5$: corrélation modérée à forte

Découverte clé

La corrélation entre l'Âge et le Spending Score vaut $r = -0,33$. C'est une corrélation négative faible à modérée : **les clients plus jeunes tendent légèrement à dépenser davantage**, mais la relation n'est pas très marquée. En revanche, le revenu et le score de dépense sont quasi indépendants ($r \approx 0$), ce qui confirme qu'on peut être riche et économe, ou modeste et grand dépensier.

2.4. Analyse du genre




Figure 3. Gauche : répartition des 200 clients par genre (Female = 112 clients soit 56%, Male = 88 clients soit 44%). Droite : distribution du Spending Score par genre.

Observations :

- La clientèle est majoritairement féminine : **112 femmes (56%)** contre **88 hommes (44%)**.
- Les deux genres présentent des distributions de Spending Score similaires, avec un pic commun autour de 45–55. Les femmes semblent légèrement plus représentées dans les scores élevés (> 70).
- Le genre seul ne permet pas de discriminer les comportements d'achat — il sera intégré comme variable complémentaire dans l'interprétation des clusters.

3. Préparation des données

3.1. Nettoyage et encodage

La colonne `CustomerID` est supprimée car elle n'apporte aucune information prédictive. La variable `Genre` est encodée numériquement (*Female* $\rightarrow 0$, *Male* $\rightarrow 1$) via un `LabelEncoder`.

Une variable dérivée est également créée pour la validation statistique :

$$\text{Spending_per_Income} = \frac{\text{Spending Score}}{\text{Annual Income (k\$)}}$$

Cette variable sera utilisée pour l'ANOVA car elle ne fait pas partie des variables d'entrée du clustering, rendant la validation plus robuste.

3.2. Normalisation des données

Pourquoi normaliser ?

Le K-means calcule des « distances » entre les clients. Or le revenu va de 15 à 137 k\$, l'âge de 18 à 70 ans et le score de 1 à 100. Si on laisse ces différences d'échelle, l'algorithme « verra » principalement le revenu (les grands nombres dominant) et ignorera presque l'âge. La normalisation remet tout à la même échelle.

L'algorithme **StandardScaler** transforme chaque variable selon :

Formule de normalisation Z-score

$$z_i = \frac{x_i - \mu}{\sigma} \quad \text{avec } \mu = \frac{1}{n} \sum_{i=1}^n x_i \quad \text{et } \sigma = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \mu)^2}$$

Après transformation : $\mathbb{E}[z] = 0$ et $\text{Var}(z) = 1$

Les features retenues pour le clustering sont :

$$\mathbf{X} = [\text{Age}_{\text{scalé}}, \text{Income}_{\text{scalé}}, \text{Score}_{\text{scalé}}] \in \mathbb{R}^{200 \times 3}$$

4. Détermination du nombre optimal de clusters

4.1. L'algorithme K-means

Fonctionnement du K-means

L'algorithme K-means est une méthode de *clustering* (regroupement non supervisé). Il cherche à partitionner les n observations en K groupes en minimisant la dispersion interne de chaque groupe.

Étapes de l'algorithme :

1. Initialiser K centroïdes aléatoirement dans l'espace des données.
2. Assigner chaque point au centroïde le plus proche (distance euclidienne).
3. Recalculer chaque centroïde comme la moyenne de son groupe.
4. Répéter les étapes 2 et 3 jusqu'à convergence.

Critère de convergence : les assignments ne changent plus d'une itération à l'autre.

Fonction objectif du K-means — Inertie (WCSS)

$$\mathcal{L}(K) = \sum_{k=1}^K \sum_{\mathbf{x}_i \in C_k} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2$$

où C_k = ensemble des points du cluster k

$\boldsymbol{\mu}_k$ = centroïde du cluster k

$\|\cdot\|$ = norme euclidienne

L'inertie mesure la somme des carrés des distances de chaque point à son centroïde.

Plus elle est faible, plus les clusters sont compacts.

4.2. Méthode Elbow**La méthode du coude en termes simples**

On fait tourner K-means pour $K = 2, 3, \dots, 10$ et on trace la courbe de l'inertie. Elle diminue toujours quand on ajoute des clusters, mais à un certain point le gain devient négligeable. Ce « coude » dans la courbe indique le K optimal — après ce point, ajouter un cluster ne compresse plus vraiment l'information.

4.3. Silhouette Score

Le Silhouette Score est une mesure de la qualité du clustering combinant la cohésion intra-cluster et la séparation inter-clusters.

Définition du Silhouette Score

Pour chaque point i , on définit :

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))} \quad s(i) \in [-1, +1]$$

$a(i)$ = distance moyenne de i aux autres points **du même cluster**

$b(i)$ = distance moyenne de i aux points du **cluster voisin le plus proche**

Le Silhouette Score global est la moyenne sur tous les points :

$$\bar{s} = \frac{1}{n} \sum_{i=1}^n s(i)$$

- $\bar{s}$ proche de +1 : clusters denses et bien séparés
- $\bar{s}$ proche de 0 : points sur la frontière entre clusters
- $\bar{s}$ proche de -1 : points potentiellement mal classifiés

4.4. Résultats




Figure 4. Gauche : Méthode Elbow — courbe de l’inertie WCSS pour $K = 2$ à $K = 10$. Le « coude » est visible en $K = 5$. Droite : Silhouette Score pour chaque K ; la barre verte correspond au score maximal.

Choix de $K = 5$ — Justification

Les deux méthodes ne donnent pas exactement le même résultat :

- **Méthode Elbow** : le coude le plus marqué de la courbe d’inertie se situe en $K = 5$, après quoi le gain devient marginal.
- **Silhouette Score** : le score est maximal en $K = 6$ ($\bar{s} = 0,428$), avec $K = 5$ très proche ($\bar{s} = 0,417$).

$K = 5$ est retenu comme choix final car il correspond au coude de la courbe Elbow et offre un Silhouette Score quasi identique à $K = 6$, tout en produisant des segments plus interprétables d’un point de vue métier.

5. Application du K-means et Visualisation

5.1. Entraînement du modèle final

Le modèle K-means est entraîné avec $K = 5$, `n_init=10` (10 initialisations aléatoires, on conserve la meilleure) et `random_state=42` pour la reproductibilité.

Listing 2. Entraînement K-means final

```

1 K_FINAL = 5
2 km_final = KMeans(n_clusters=K_FINAL, random_state=42, n_init=10)
3 df['Cluster'] = km_final.fit_predict(X_scaled)
4
5 # Recuperation des centroides dans l'espace original
```

```

6 centroids_scaled = km_final.cluster_centers_
7 centroids_original = scaler.inverse_transform(centroids_scaled)
8
9 # Silhouette Score final
10 sil_final = silhouette_score(X_scaled, df['Cluster'])
11 print(f"Silhouette Score : {sil_final:.4f}")

```

5.2. Visualisation 2D principale




Figure 5. Nuage de points Revenu annuel vs Spending Score, coloré par cluster. Les étoiles blanches représentent les centroïdes (client moyen de chaque groupe). On distingue clairement 5 « îlots » bien séparés.

Qu'est-ce qu'un centroïde ?

Un centroïde est le « client moyen » d'un cluster. Si on calcule la moyenne de l'âge, du revenu et du score de tous les clients d'un groupe, on obtient les coordonnées du centroïde. C'est le point représentatif du groupe, son « centre de gravité ». Dans la figure, les étoiles blanches montrent exactement ces centres.

5.3. Réduction de dimension — PCA





Figure 6. Projection PCA en 2D. Les 3 dimensions d'origine sont compressées en 2 composantes principales ($PC1 = 44,3\%$ de variance, $PC2 = 33,3\%$), soit **77,6% de la variance totale** conservée.

Analyse en Composantes Principales (PCA)


La PCA cherche les directions de l'espace dans lesquelles les données varient le plus. La première composante principale (PC1) capture le maximum de variance ; la deuxième (PC2) capture le maximum de ce qui reste, orthogonalement à PC1.

La PCA est comme aplatir une sphère 3D en un cercle 2D en perdant le moins d'information possible. La variance expliquée par chaque composante indique quelle fraction de l'information totale est conservée. Si les couleurs (clusters) restent séparées après aplatissement, les groupes sont robustes.

5.4. Radar Chart et Heatmap



(a) Radar Chart normalisé. Chaque axe représente une variable normalisée entre 0 et 1. Plus la ligne d'un cluster est étendue sur un axe, plus sa valeur est élevée.



(b) Heatmap des moyennes par cluster. Une cellule plus foncée (rouge) correspond à une valeur plus élevée. Vue synthétique pour comparer tous les segments.

Figure 7. Profils des clusters : Radar Chart (gauche) et Heatmap (droite).

6. Profils des Segments Clients

6.1. Tableau récapitulatif

Table 3. Profil moyen des 5 clusters identifiés par K-means

#	Nom du segment	N	Âge moy.	Revenu moy.	Score moy.	% Femmes
0	Modérés équilibrés	20	46,2 ans	26,8 k\$	18,4/100	60,0%
1	Jeunes dépensiers	54	25,2 ans	41,1 k\$	62,2/100	59,3%
2	Clients VIP	40	32,9 ans	86,1 k\$	81,5/100	55,0%
3	Hauts revenus économes	39	39,9 ans	86,1 k\$	19,4/100	48,7%
4	Budget serré	47	55,6 ans	54,4 k\$	48,9/100	57,4%




Figure 8. Boxplots comparatifs par cluster pour chaque variable. Les chiffres au-dessus indiquent la médiane de chaque groupe. On voit clairement que chaque cluster occupe une position distincte sur les 3 variables.

6.2. Qui dépense le plus ? Interprétation et cibles marketing

Classement des segments par dépense

En classant les clusters par Spending Score décroissant, on identifie trois niveaux de comportement d'achat bien distincts :

Rang	Segment	Score moy.	Profil
1 ^{er}	Clients VIP (C2)	81,5 / 100	Haut revenu + fort spending
2 ^e	Jeunes dépensiers (C1)	62,2 / 100	Revenu modéré + fort spending
3 ^e	Budget serré (C4)	48,9 / 100	Revenu moyen + spending moyen
4 ^e	Modérés équilibrés (C0)	18,4 / 100	Faible revenu + faible spending
5 ^e	Hauts revenus économes (C3)	19,4 / 100	Haut revenu + faible spending

Le paradoxe des clusters 2 et 3

Les clusters 2 et 3 ont **exactement le même revenu moyen** (86,1 k\$) mais des comportements radicalement opposés. C'est l'une des découvertes les plus importantes de cette segmentation :

- **Cluster 2 — Clients VIP** : revenu élevé *et* forte propension à dépenser. Ce sont les clients les plus précieux, qui génèrent le plus de chiffre d'affaires. **Priorité : les fidéliser et augmenter leur panier moyen.**
- **Cluster 3 — Hauts revenus économes** : même revenu mais score de dépense très faible (19,4). Ces clients ont les moyens mais ne les dépensent pas dans ce centre commercial. **Priorité : comprendre les freins et les activer via des expériences premium et personnalisées.**

Que retenir pour la stratégie ?

Le segment **Clients VIP (C2)** représente seulement 20% des clients (40 sur 200) mais génère proportionnellement beaucoup plus de valeur grâce à un score de 81,5/100. Ce sont eux qu'on doit protéger en priorité avec des offres exclusives.

Le segment **Jeunes dépensiers (C1)** est le plus nombreux (54 clients, 27% du total) avec un bon score de 62,2/100 malgré un revenu modéré. Fidéliser ce segment aujourd'hui, c'est investir dans les **Clients VIP de demain**.

6.3. Description détaillée des segments

6.3.1. Cluster 0 — Modérés équilibrés

Cluster 0 20 clients · Âge 46,2 ans · Revenu 26,8 k\$ · Score 18,4/100

Profil intermédiaire sur l'âge mais avec un faible revenu et un faible score de dépense. Ce segment de clients matures et économes représente un potentiel de fidélisation par la valeur perçue et la régularité des offres.

Actions marketing recommandées :

- Offres de fidélité progressives (points, récompenses)
- Newsletters personnalisées avec promotions saisonnières
- Cross-selling sur des catégories adjacentes à leurs achats habituels

6.3.2. Cluster 1 — Jeunes dépensiers

Cluster 1 54 clients · Âge 25,2 ans · Revenu 41,1 k\$ · Score 62,2/100

Segment le plus grand (27% du total), le plus jeune avec un score de dépense élevé malgré un revenu modéré. Fort potentiel à long terme si fidélisés tôt.

Actions marketing recommandées :

- Facilités de paiement (BNPL, crédit 0% court terme)
- Campagnes sur réseaux sociaux (Instagram, TikTok)
- Offres flash exclusives et collaborations avec des influenceurs

6.3.3. Cluster 2 — Clients VIP

Cluster 2 40 clients · Âge 32,9 ans · Revenu 86,1 k\$ · Score 81,5/100

Segment le plus rentable du portefeuille. Ces clients combinent le revenu le plus élevé *et* le score de dépense le plus fort — ils ont les moyens et la volonté de dépenser. C'est la

cible prioritaire de toute stratégie marketing haut de gamme, avec la valeur client à long terme (LTV) la plus élevée.

Actions marketing recommandées :

- Programme de fidélité haut de gamme (Gold/Platinum) avec avantages exclusifs
- Personal shopper dédié et accès anticipé aux nouvelles collections
- Invitations à des événements privés et avant-premières

6.3.4. Cluster 3 — Hauts revenus économes

Cluster 3 39 clients · Âge 39,9 ans · Revenu 86,1 k\$ · Score 19,4/100

Clients avec un revenu identique au Cluster 2 (86,1 k\$) mais un score de dépense très faible (19,4). Ils ont le pouvoir d'achat mais ne l'utilisent pas dans ce centre. C'est un **potentiel inexploité** — la cible idéale pour des stratégies d'activation et de conversion.

Actions marketing recommandées :

- Événements VIP privés pour créer une expérience premium (showrooms, dégustations)
- Communication axée sur la qualité, la rareté et l'exclusivité
- Programme de parrainage avec bénéfices premium pour engager leur réseau

6.3.5. Cluster 4 — Budget serré

Cluster 4 47 clients · Âge 55,6 ans · Revenu 54,4 k\$ · Score 48,9/100

Segment le plus âgé avec un revenu moyen et un score de dépense modéré. Clients à fidéliser avec des offres accessibles et un bon rapport qualité/prix.

Actions marketing recommandées :

- Promotions régulières, coupons de réduction et soldes ciblés
- Communication budget-friendly : meilleur rapport qualité/prix
- Programme de fidélité accessible avec récompenses rapides

7. Validation Statistique — ANOVA

7.1. Stratégie de validation

Un beau graphique ne suffit pas en statistique. On doit *prouver* formellement que les différences observées entre clusters ne sont pas dues au hasard. L'ANOVA (Analysis of Variance) est l'outil adapté.

L'ANOVA en termes simples

Imagine 5 bols de fruits. L'ANOVA répond à la question : « Les fruits dans ces bols viennent-ils vraiment de variétés différentes, ou les différences qu'on observe viennent-elles juste du hasard ? »

On compare la **variance entre les bols** (à quel point les bols sont différents entre eux) à la **variance à l'intérieur des bols** (à quel point les fruits varient dans un même bol). Si le ratio est grand, les bols sont vraiment différents.

Variable dépendante choisie :

$$Y = \text{Spending_per_Income} = \frac{\text{Spending Score}}{\text{Annual Income (k\$)}}$$

Ce choix est stratégique : cette variable dérivée n'a pas été utilisée dans le clustering, ce qui rend la validation plus convaincante.

7.2. Étape 1 — Test de normalité (Shapiro-Wilk)

Test de Shapiro-Wilk

Le test vérifie si les données d'un groupe suivent une loi normale.

$\mathcal{H}_0$: les données suivent une loi normale $\mathcal{H}_1$: la distribution n'est pas normale

La statistique W est basée sur la corrélation entre les données ordonnées et les quantiles normaux théoriques. Si $p > \alpha = 0,05$, on ne rejette pas $\mathcal{H}_0$.

Table 4. Résultats du test de Shapiro-Wilk par cluster ($\alpha = 0,05$)

Cluster	Statistique W	p-value	Décision	Conclusion
0	0,9416	0,2574	Ne rejette pas $\mathcal{H}_0$	Normale
1	0,8402	< 0,0001	Rejette $\mathcal{H}_0$	Non-normale
2	0,9776	0,6015	Ne rejette pas $\mathcal{H}_0$	Normale
3	0,9065	0,0034	Rejette $\mathcal{H}_0$	Non-normale
4	0,9830	0,7186	Ne rejette pas $\mathcal{H}_0$	Normale

2 clusters sur 5 (C1 et C3) présentent une déviation significative à la normalité. Les clusters C0, C2 et C4 suivent une loi normale. L'ANOVA est reconnue comme robuste à des écarts

modérés de normalité lorsque les effectifs sont suffisants ($n_k \in [20, 54]$). On procède tout en notant cette limite.

7.3. Étape 2 — Test d'homogénéité des variances (Levene)

Test de Levene

$$\mathcal{H}_0 : \sigma_1^2 = \sigma_2^2 = \dots = \sigma_K^2 \quad (\text{homoscédasticité})$$

$$\mathcal{H}_1 : \exists k, k' \text{ tels que } \sigma_k^2 \neq \sigma_{k'}^2$$

La statistique de Levene est construite à partir des déviations par rapport à la médiane du groupe.

Résultat observé : $W = 22,0277$, $p < 0,0001$. On rejette $\mathcal{H}_0$: les variances sont hétérogènes entre clusters (hétéroscédasticité). Une ANOVA de Welch serait idéale, mais on procède avec l'ANOVA classique à titre démonstratif, en notant cette limite.

7.4. Étape 3 — ANOVA à 1 facteur

ANOVA à 1 facteur — Test F de Fisher

On décompose la variance totale en deux composantes :

$$SS_{\text{total}} = SS_{\text{between}} + SS_{\text{within}}$$

$$SS_{\text{between}} = \sum_{k=1}^K n_k (\bar{y}_k - \bar{y})^2 \quad SS_{\text{within}} = \sum_{k=1}^K \sum_{i \in C_k} (y_i - \bar{y}_k)^2$$

La statistique de Fisher :

$$F = \frac{SS_{\text{between}}/(K-1)}{SS_{\text{within}}/(N-K)} = \frac{MS_{\text{between}}}{MS_{\text{within}}} \quad F \sim \mathcal{F}(K-1, N-K)$$

$$\mathcal{H}_0 : \mu_1 = \mu_2 = \dots = \mu_K \quad (\text{toutes les moyennes sont égales})$$

$$\mathcal{H}_1 : \text{au moins une moyenne diffère}$$

$$\text{Règle de décision} : \text{on rejette } \mathcal{H}_0 \text{ si } p < \alpha = 0,05$$

7.4.1. Résultats numériques

Table 5. Résultats de l'ANOVA à 1 facteur sur *Spending_per_Income*

Source	SS	df	MS	F
Entre clusters (Between)	—	$K - 1 = 4$	—	35,1482
Intra-clusters (Within)	—	$N - K = 195$	—	—
<i>p-value</i>	< 0,0001			




Figure 9. Gauche : boxplots de *Spending_per_Income* par cluster. Droite : moyennes avec intervalles de confiance à 95% ($\pm 1,96 \cdot SE$). $F = 35,15$, $p < 0,0001$.

Décision statistique

Avec $F = 35,1482$ et $p < 0,0001 < \alpha = 0,05$, on **rejette** $\mathcal{H}_0$ avec une confiance de 99,99%.

La probabilité d'observer ces différences par hasard est quasi nulle. **Les clusters diffèrent significativement sur la variable *Spending_per_Income*.**

7.5. Étape 4 — Tests post-hoc de Tukey HSD

L'ANOVA indique qu'au moins un groupe diffère, mais ne précise pas lesquels. Le test de Tukey HSD (Honestly Significant Difference) compare toutes les paires de clusters deux à deux en contrôlant le risque d'erreur global (Family-Wise Error Rate). **Résultat : 6 paires sur 10** sont significativement différentes ($p_{\text{adj}} < 0,05$), confirmant la robustesse de la segmentation.

Table 6. Résultats complets du test post-hoc Tukey HSD

Groupe 1	Groupe 2	Diff. moyennes	p-adj	Significatif?
C0	C1	+1,3165	< 0,001	Oui
C1	C2	−1,0336	< 0,001	Oui
C1	C3	−1,7738	< 0,001	Oui
C1	C4	−1,0845	< 0,001	Oui
C2	C3	−0,7402	0,0002	Oui
C3	C4	+0,6893	0,0003	Oui
C0	C2	+0,2829	0,6425	Non
C0	C3	−0,4573	0,1774	Non
C0	C4	+0,2320	0,7744	Non
C2	C4	−0,0509	0,9978	Non

Listing 3. Implémentation du test Tukey HSD

```

1 from statsmodels.stats.multicomp import pairwise_tukeyhsd
2
3 tukey = pairwise_tukeyhsd(
4     df_model['Spending_per_Income'], # variable dependante
5     df_model['Cluster'],             # groupes
6     alpha = 0.05
7 )
8 print(tukey.summary())

```

8. Conclusion & Perspectives

8.1. Synthèse des résultats

Ce projet démontre comment combiner **Machine Learning non supervisé** et **tests statistiques rigoureux** pour produire des insights métier actionnables.

Table 7. Résumé des résultats obtenus

Critère	Résultat
Nombre de clusters optimal	$K = 5$ (Elbow + Silhouette convergents)
Silhouette Score	$\bar{s} = 0,4166$ — clustering de qualité correcte
Corrélation Âge/Score	$r = -0,33$ — tendance négative faible à modérée
Statistique ANOVA	$F = 35,1482$ — différences significatives entre groupes
p-value ANOVA	$p < 0,0001$ — résultat hautement significatif
Paires Tukey significatives	6 paires sur 10 ($p_{adj} < 0,05$)

8.2. Limites du projet

- **Taille du dataset** : 200 observations est un échantillon modeste. Des résultats plus stables nécessiteraient un corpus plus large.
- **Hypothèse sphérique de K-means** : K-means suppose des clusters de forme sphérique et de taille comparable, ce qui peut ne pas refléter la réalité.
- **Variables limitées** : Le dataset ne contient que 3 variables. Des données comportementales (fréquence de visite, catégories achetées) enrichiraient considérablement la segmentation.
- **Stabilité temporelle** : Les clusters sont calculés à un instant t . Un client peut changer de segment au fil du temps.

8.3. Perspectives d'amélioration

1. **Enrichissement des données** : Intégrer un modèle RFM (Récence, Fréquence, Montant) pour une segmentation plus fine et plus directement actionnable.
2. **Déploiement** : Développer un dashboard interactif avec Streamlit ou Power BI permettant au métier de visualiser les clusters en temps réel.
3. **Segmentation dynamique** : Mettre en place un système de ré-entraînement périodique pour suivre l'évolution des profils clients.

8.4. Compétences développées

Ce projet m'a permis de mobiliser et d'approfondir plusieurs compétences fondamentales pour un data scientist junior :

Compétence	Application dans ce projet
Analyse exploratoire (EDA)	Distributions, corrélations, visualisation avancée
Prétraitement des données	Normalisation, encodage, feature engineering
Machine Learning	K-means, sélection de K (Elbow, Silhouette), PCA
Statistiques inférentielles	ANOVA, Shapiro-Wilk, Levene, Tukey HSD
Visualisation	matplotlib, seaborn, plotly (3D interactif), radar chart
Reproductibilité	Graine aléatoire, notebooks documentés, commentaires
Communication	Interprétation métier, rapport structuré

Récapitulatif des métriques clés

Table 8. Synthèse quantitative complète du projet

Métrique	Valeur	Interprétation
Nombre de clients analysés	200	Jeu de données complet, sans valeur manquante
Nombre de clusters optimal	$K = 5$	Convergence Elbow + Silhouette Score
Silhouette Score final	0,4166	Clustering de qualité correcte
Corrélation Âge / Score	$r = -0,33$	Tendance négative faible à modérée
Statistique F (ANOVA)	35,1482	Différences significatives entre groupes
p-value (ANOVA)	$< 0,0001$	Résultat hautement significatif ($\alpha = 0,05$)
Paires Tukey significatives	6/10	6 clusters diffèrent significativement deux à deux

200

clients analysés

$F = 35,1482$

Statistique ANOVA

5

segments identifiés

$p < 0,0001$

Clusters validés

$\bar{s} = 0,4166$

Silhouette Score

6/10

Paires Tukey sign.